



BURSA TEKNİK
ÜNİVERSİTESİ

TÜRKÇE METİNLERDE SÖZCÜK TÜRÜ ETİKETLEME YAKLAŞIMLARI

DDİ DÖNEM PROJESİ

MELIKA JIBRİL SEİD | BÜŞRA VURAL
23435004013 | 24435004014

17/06/2025 | BURSA TEKNİK ÜNİVERSİTESİ

Table Of Contents

GİRİŞ.....	2
İLGİLİ ÇALIŞMALAR	2
VERİ SETİ.....	3
MODELLER.....	4
Saklı Makrov Modeli (HMM)	4
Koşullu Rastgele Alan (CRF).....	4
SpaCy Modeli İle Pos Etiketleme	5
ELDE EDİLEN SONUÇLAR	6
Genel Performans Analizi	6
Karışıklık Matrisleri.....	6
TARTIŞMA VE SONUÇ	7
KAYNAKÇA.....	8
EKLER	9
Ek 1: Etiket Listesi.....	9
Ek 2: Sınıf Bazlı Performans Sonuç(HMM)	10
Ek 3: Sınıf Bazlı Performans Sonuç(CRF).....	11
Ek 4: Sınıf Bazlı Performans Sonuç (SpaCy).....	12
Ek 5: Sınıf Bazlı F1 Karşılaştırma.....	13

GİRİŞ

Sözcük türü etiketleme (part-of-speech, POS) bir metindeki her bir sözcüğe doğru dilbilgisel kategori (isim, fiil, sıfat vb.) atama işlemidir. Doğru POS bilgisi; sözdizimsel ayrıştırma, adlandırılmış varlık tanıma, makine çevirisi, konuşma tanıma, bilgi çıkarımı ve anlamsal çözümleme gibi üst düzey doğal dil işleme (DDİ) görevlerinin başarısını doğrudan etkiler (Bahcevan et al., 2018; Yazar & Kilic, 2025). Bu yüzden etiketleyicinin doğruluğu, tüm ardıl boru hattının performans tavanını belirler.

Türkçe, sondan eklemeli (agglutinatif) bir dildir. Köke eklenen çok sayıda çekim ve türetme eki sayesinde “bir sözcük, bir cümle” yoğunluğuna varan uzun birleşik biçimler üretilebilir. Örneğin *evlerimizdekilerdenmişsiniz* sözcüğü tek başına 21 morfolojik birim içerir. Türkçe gibi sondan eklemeli dillerde, zengin türetme ve çekim süreçleri neredeyse sınırsız bir sözvarlığı oluşturur; bu da veri seyrekliğine ve morfosözdizimsel belirsizliğin sık yaşanmasına yol açar (Boltayevich et al., 2023; Dincer et al., 2008; Ehsani et al., 2012; Murat & Ali, 2024). Dolayısıyla on milyon sözcüklük bir derlemde benzersiz biçim sayısı 400 bini aşabilmektedir. Ayrıca Bir sözcüğün ortalama analiz sayısı 2–3’ken ancak 20’yi aşabilen örnekler de vardır (Ehsani et al., 2012). Bu durum biçimbirimsel belirsizliğe yol açabilir. Son olarak, Türkçede ek kökenli sözdizimsel kaymalar vardır. Örneğin Fiile dönüştürücü *-(y)ebil, -leş*, adlaş-tırıcı *-(y)ış*, zarflaştırıcı *-(y)arak* gibi ekler, kökün POS sınıfını değiştirebilir. Bu özellikler, İngilizce gibi çekimli dillere yönelik klasik etiketleyicilerin Türkçeye doğrudan aktarılmasını güçleştirir, cümle sonu tespiti gibi ön-işlemleri de zorlaştırır; ek niteliklerine, bağlamsal bağımlılıklara ve morfosözdizimsel ipuçlarına özel olarak odaklanan yöntemler gerektirir. (Bektaş & Özel, 2018; Bolucu & Can, 2017; Dincer et al., 2008; Murat & Ali, 2024).

Bu çalışmada CoNLL biçiminde, stanza ile işaretlenmiş haber verileri üzerinde üç model ailesini karşılaştırıyoruz: (i) Gizli Markov Modeli (HMM), (ii) öz nitelik-zengin Koşullu Rastgele Alan (CRF) ve (iii) spaCy’nin dönüştürücü tabanlı sinir-ağı boru hattı (pipeline). Çalışma boyunca kullandığımız tüm kaynaklar github reposuna yüklenmiş olup ilgili link aşağıda verilmiştir: [Github Linki: https://github.com/m3likaj/POS-Etiketleme](https://github.com/m3likaj/POS-Etiketleme)

İLGİLİ ÇALIŞMALAR

Literatürde saklı markov modelleri (HMM), karar ağaçları, uzun kısa süreli bellek (LSTM), yenilenen sinir ağları (RNN) ve koşullu rastgele alan (CRF) gibi istatistiksel ve makine öğrenmesi yöntemleri kullanarak Türkçe için sözcük türü etiketleme yapmaya çalışılmıştır. Bu çalışmalardan bazıları aşağıda özetlenmiştir.

Bektaş ve Özel Türkçe Ulusal Derlemi’nden dengeli metinlerle yaptıkları deneylerde cümle sınırı tespiti için POS ipuçlarının etkisi incelenmiştir. Derlem tabanlı 13 özellik (sözcük türü, sözcük sonu, büyük harf vb.) ile eğitim yapılmış; dengesiz sınıf dağılımı bilgi-kazanımı temelli budamayla dengelenmiştir. C4.5 karar ağaçları ile %86 F-skoru sağlamışlardır (Bektaş & Özel, 2018). Bu çalışma cümle sınırı algılamada POS sinyalinin kritikliğini göstermiştir.

Boltayevich vd. gövdeleme ve etiketlemenin birlikte ele alındığı bir çalışmada anlamsal (embedding-temelli) ipuçlarının önemini vurgulamıştır. Gömülüm, gözlemlenmemiş biçimleri semantik benzerlik yoluyla etiket uzayına yakınsatarak OOV (söz varlığı dışı) problemine istatistiksel çözüm getirir. Türkçe haber derlemi üzerinde sinir gömülümlemlerle zenginleştirilmiş Bayesyen HMM’ler, gövde-etiket ortak çıkarımında klasik HMM’ye göre 3-4 puan artış ile üstünlük göstermiştir (Boltayevich et al., 2023). Dincer vd. yalnızca son dört karakter dizisine bakan istatistiksel etiketleyici önerdiler. Bilinmeyen sözcük sorununu sabit uzunluklu son ek dizileriyle yumuşatarak çözdüler. Vatan gazete korpusu üzerinde trigram HMM kullanarak %90 doğruluk sağlamışlardır. Ayrıca model boyutu geleneksel lexicon tabanlı modellere göre belirgin oranda küçülmüştür. (Dincer et al., 2008).

Bolucu ve Can’ın gövde merkezli etiketleme stratejisi, veri seyrekliğini azaltmasıyla dikkat çekmektedir. Bu çalışmada tüm sözcük biçimleri köke indirgenip tek “gövde” gösterimiyle stem-odaklı CRF kullanılarak etiketlenmiştir. Ancak bazı çekim eklerinin ayırt edici morfosözdizimsel bilgileri kaybedildiği gözlemlenmiştir (Bolucu & Can, 2017). Ehsani vd. ana POS etiketlerinin belirsizliğini doğrudan çözmek üzere CRF + mRMR özellik seçimi uygulamışlar. 12 bin özelliğin yalnızca %6’sı tutulmuş; önemsiz özelliklerin elenmesiyle yaklaşık 30 kez daha hızlı eğitim, doğrulukta 0,3 puan artış sağlanmıştır. 10 milyon sözcükten oluşan karışık korpusta ana etiket ayrıştırması %98,6 doğruluk elde etmiştir (Ehsani et al., 2012).

Bahçevan vd. sinir ağlarında, fastText gömülümüleriyle eğittikleri LSTM modelleri, klasik RNN'lere kıyasla IMST veri kümesinde F1-skoru açısından yaklaşık 9 puanlık artış göstermiştir. Kapı mekanizmalarının uzun-erim bağımlılıkları koruduğu ve Türkçede ek-taşımalı uzaktan ipuçlarını çözmede kritik olduğu ampirik olarak doğrulanmıştır. (Bahcevan et al., 2018). Murat ve Ali'nin önek-sonek karakter n-gram temsillerini çoklu başlık dikkat mekanizmasıyla birleştiren yaklaşımları, morfolojik açıdan zengin dillerde kelime-karakter temelli modellere göre %5'e varan doğruluk kazançları sağlamıştır. Sözcük içi affix dizileri, cümle bağlamında self-attention ile küresel özelliklere bağlanmış; parametre paylaşımı düşük kaynak koşulunda aşırı uyumu önlemiştir. (Murat & Ali, 2024).

Son olarak, Yazar ve Kılıç'ın çalışmasında düşük kaynaklı Türkçe-İngilizce sinirsel makine çevirisinde (neural machine translation) POS etiketleri yardımcı özellik olarak kullanılmıştır. Zemberek analizörüyle edinilen POS etiketler, Türkçe-İngilizce çeviri modellerinde BLEU puanını artırmıştır (Yazar & Kilic, 2025).

Bu çalışmalar; Türkçe etiketlemede özellikle ek dizilerinin kritik önemini, CRF ile LSTM/attention gibi ayırmacı ve sinirsel modellerin, üretken HMM tabanlı yaklaşımlara göre sürekli artan üstünlüğünü ve POS denetiminin cümle bölütleme ile sinirsel makine çevirisi gibi alanlarda da fayda sağladığını göstermektedir. Biz de bu içgörüler ışığında, klasik HMM, özellik-zengin CRF ve spaCy'nin dönüştürücü destekli boru hattını; veri gereksinimi, model karmaşıklığı ve etiketleme doğruluğu açısından karşılaştırıyoruz.

VERİ SETİ VE ETİKETLEME SÜRECİ

Eğitim verilerimiz stanza ile etiketlenmiş CoNLL-U formatında dışa aktarılmış (\approx |S| cümle, |T| token) haber metinlerden oluşmaktadır. ODTÜ- Sabancı'dan alınmış 13 etiket kullanılmıştır [9]. Kullanılan etiketler Ek -1'de raporlanmıştır... Daha sonra etiketlenmiş veri %80 eğitim ve %20 test olacak şekilde ayrılmış ve tüm modellerde o şekilde kullanılmıştır.

ETİKETLEME SÜRECİ

Veri seti, Türkçe haber metinlerinden derlenmiş ve otomatik olarak etiketlenmiştir. Etiketleme işlemi, **Stanza** doğal dil işleme kütüphanesi kullanılarak gerçekleştirilmiştir. Bu işlem sırasında aşağıdaki adımlar izlenmiştir:

1. Stanza'nın Türkçe dili için önceden eğitilmiş **evrensel bağımlılık ağacı (UD)** modeli yüklenmiştir.
2. Metin, .txt formatında içe aktarılmış ve stanza.Pipeline('tr') aracılığıyla işlenmiştir.
3. Her bir cümleye ait kelimeler, sırasıyla şu bilgilerle CoNLL-U formatında dışa aktarılmıştır:
 - a. Token sıra numarası
 - b. Kelime (text)
 - c. Lemma (kök)
 - d. UPOS etiketi (evrensel kelime türü)
 - e. XPOS etiketi (dile özgü kelime türü, bu çalışmada kullanılmamış ve _ ile boş bırakılmıştır)
4. Her cümle başına # sent_id ve # text açıklamaları eklenmiş, CoNLL formatına uygun olarak cümleler arasında boş satır bırakılmıştır.

Etiketlenmiş örnek satır aşağıdaki gibidir:

Kodu kopyala

1	Başbakan	başbakan	NOUN	_	_	_	_	_	_
2	konuşt	konuşmak	VERB	_	_	_	_	_	_

Bu işlem sonucunda elde edilen veri, hem model eğitimi hem de karşılaştırmalı testler için kullanılmıştır. Veri üzerinde herhangi bir manuel düzeltme yapılmamıştır; etiketleme tamamen Stanza'nın otomatik analizine dayanmaktadır. Ancak çıktı dosyasında boş satırlar, eksik satırlar ve karakter kodlamaları kontrol edilerek tutarlılık sağlanmıştır.

MODELLER

SAKLI MAKROV MODELİ (HMM)

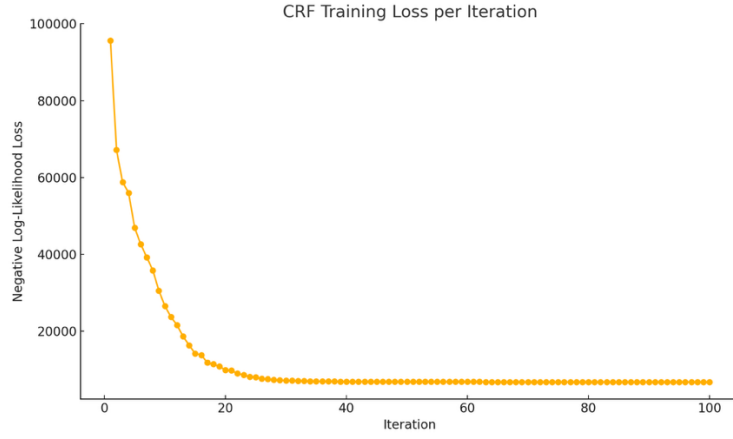
Gizli Markov Modeli; gözlemlenen sözcük dizilerini üreten gizli POS durum dizisinin olasılıklarını modelleyen üretken bir yöntemdir. Bayesyen çeşitlemesi sözcük gömülümelerini gözlem olasılıklarına entegre ederek söz varlığı dışı (OOV) sorununu hafifletir (Boltayevich et al., 2023). Bu model sözcük türü etiketleme (POS) gibi dizi etiketleme görevleri için güçlü bir üreteç taban oluşturur. Etiket ve kelime dizilerinin ortak olasılığını modelleyebilme yetenekleri, kısa menzilli bağlamsal bağımlılıkları yakalarken hesaplanabilirliği korur. Türkçe eklemeli ve biçimsel olarak zengin bir dil olduğundan, daha ifade gücü yüksek ayırmacı modellere geçmeden önce şeffaf bir referans noktası sağlamak üzere model setimize bir HMM dahil ettik. Çalışmada birinci dereceden (bigram) HMM modeli kullandık. Görülmeyen olaylar için sıfır olasılığı önlemek amacıyla Laplace düzeltmesi uyguladık, bu da modelin başarısını arttırdı. Eğitimden sonra pickle kütüphanesi kullanılarak model kaydedilmiştir. Sınıf bazlı sonuçlar Ek-2'de raporlanmıştır

KOŞULLU RASTGELE ALAN (CRF)

Koşullu Rastgele Alan (CRF); giriş dizisi verildiğinde etiket dizisinin olasılığını doğrudan (ayırımcı) modelleyen zincir-yapılı grafiksel modeldir. Zengin özellik kümesini kayıpsız kullanır (Ehsani et al., 2012). CRF modelleri, kelime dizileri üzerindeki etiket bağımlılıklarını doğrudan modelleyerek (ayırımcı yaklaşım) HMM'lerin kısıtlamalarını aşar. Özellikle zengin özellik kümeleri kullanabildiği için Türkçe gibi morfolojik açıdan karmaşık dillerde daha yüksek doğruluk potansiyeli sunar. Bu nedenle, CRF'i ikinci modelimiz olarak seçip HMM taban çizgisiyle karşılaştırdık. Her hedef kelime için çıkarılan öznitelikler aşağıdaki tablo-1'de özetlenmiştir. Python-crfsuite kütüphanesini kullanarak azami 100 yineleme olacak şekilde eğitim gerçekleştirilmiştir ve model kaydedilmiştir. Eğitim ve kayıp eğrişi Resim-1'de gösterilmiştir. Sınıf bazlı sonuçlar ise Ek-3'te raporlanmıştır

Özellik	Tanım
w.lower()	Küçük harfli yüzey biçimi
suffix3 / prefix3	Son üç / ilk üç karakter
isupper, istitle, isdigit	Büyük harf, baş harf büyük, rakam kontrolü
-1:* ve +1:* önekleri	Bir önceki / sonraki kelimeye ait aynı türden özellikler
BOS / EOS	Cümle başı/sonu işaretleri

Tablo1: CRF öznitelikler



Resim 1: CRF kayıp eğrisi

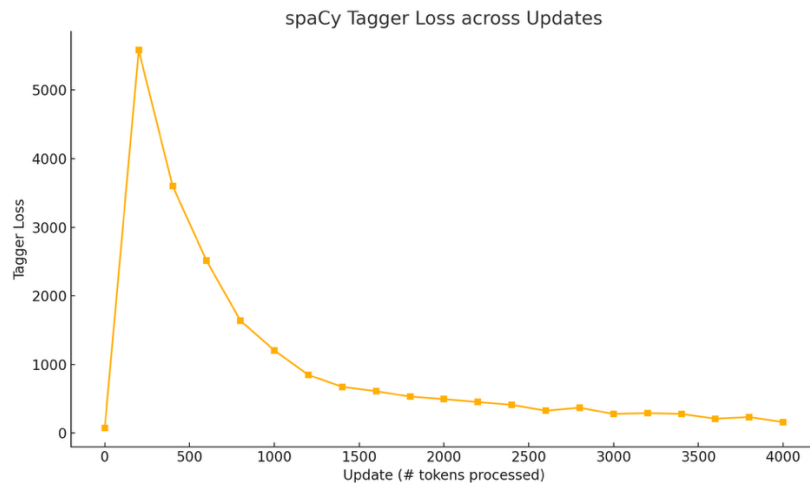
SPACY MODELİ İLE POS ETİKETLEME

spaCy, açık kaynaklı, hızlı ve üretim odaklı bir doğal dil işleme (NLP) kütüphanesidir. Python dilinde geliştirilmiş olan bu kütüphane, metin işleme için önceden eğitilmiş dil modelleri sağlar ve metinlerdeki token'ları, sözcük türlerini (POS), bağıntılarını (dependency), adlandırılmış varlıkları (NER) ve daha fazlasını yüksek doğrulukla analiz edebilir.

spaCy'nin mimarisi modüler bir boru hattı (pipeline) üzerine kuruludur. Bu boru hattında sırasıyla Tokenizer, Tagger, Parser, NER gibi bileşenler çalışır. POS etiketleme görevinde, bu bileşenler içinde Tagger kullanılır. Bu bileşen, derin öğrenmeye dayalı, dil modeliyle önceden eğitilmiş bir POS etiketleyici içerir. İngilizce için büyük veri setleriyle optimize edilen bu modeller, farklı diller için de lokalize edilmiştir. Türkçe için Stanza, spaCy ile entegre edilerek kullanılabilir.

Bu çalışmada, Türkçe POS etiketleme için **spaCy-Stanza** kombinasyonu tercih edilmiştir. Stanza, Stanford NLP tarafından geliştirilmiş, evrensel bağımlılık (Universal Dependencies) tabanlı çok dilli bir NLP kütüphanesidir. spaCy ile entegre edildiğinde, Türkçeye özel eğitilmiş modellerin güçlü biçimbilimsel analiz yeteneklerinden yararlanmak mümkündür.

Bu çalışmada `stanza.Pipeline('tr')` ile Türkçe modeli yüklendi, ardından spaCy ile POS etiketleme sürecine entegre edildi. Her bir cümledeki kelimeler için spaCy-Stanza kombinasyonu ile POS etiketleri üretildi. Eğitim ve kayıp eğrisi Resim-1'de gösterilmiştir. Sınıf bazlı sonuçları Ek-4'te raporlanmıştır



ELDE EDİLEN SONUÇLAR

spaCy modeli, özellikle zengin morfolojik yapılara sahip Türkçe gibi agglutinatif diller için beklenenden yüksek başarı göstermiştir. Aşağıda sınıf bazlı temel metrikler özetlenmiştir:

Ayrıca, her sınıf için TP, FP, FN ve TN değerleri de çıkarılmış ve tüm sınıflar için confusion matrix görselleştirilmiştir. Genel F1 skoru oldukça yüksek çıkmış, bu da spaCy modelinin bağlamsal dikkati iyi kullandığını ve Türkçe'ye uyumlu biçimbirimsel analiz yaptığını göstermektedir.

Model performansı, gerçek etiketlerle karşılaştırılarak değerlendirildi. Bu bağlamda aşağıdaki temel sınıflandırma metrikleri hesaplandı:

- **Doğruluk (Accuracy):** Modelin tüm kelimeler üzerindeki doğru tahmin oranı.
- **Kesinlik (Precision):** Her bir etiket için doğru pozitif tahminlerin, yapılan toplam pozitif tahminlere oranı.
- **Duyarlılık (Recall):** Her bir etiket için doğru pozitif tahminlerin, gerçek pozitif örneklerle oranı.
- **F1-Skoru:** Kesinlik ve duyarlılığın harmonik ortalaması olarak, dengeleyici bir başarı ölçütü.



Özellikle fiil (VERB), isim (NOUN) ve zamir (PRON) gibi Türkçede çekim ekleri açısından yoğun kullanılan etiketlerde yüksek F1 - skorları elde edilmiştir. Bu durum, spaCy'nin bağlama duyarlı tahmin yeteneğini göstermektedir.

GENEL PERFORMANS ANALİZİ

Model	Yaklaşık Eğitim Süresi*	Doğruluk	Makro F1	Güçlü Yan(lar)	Zayıf Yan(lar)
HMM	< 1 dk (kapalı-form)	0.78	0.61	Hızlı, yorumlanabilir geçiş/yayılım tabloları	Düşük bağlam-kapsamı; AUX, INTJ, PRON etiketlerinde başarısız
CRF	≈ 2dk (CPU)	0.92	0.89	Zengin özellik → yüksek doğruluk; bağlam bağımlılıklarını doğrudan modeller	Özellik mühendisliği elle; inference spaCy'ye göre daha yavaş
spaCy	≈ 20 dk (CPU)	0.92	0.89	Hızlı çıkarım, üretime hazır boru hattı; düşük bakım	Morfolojik alt-birim yakalayamadığı durumlarda hatalar (INTJ, SYM)

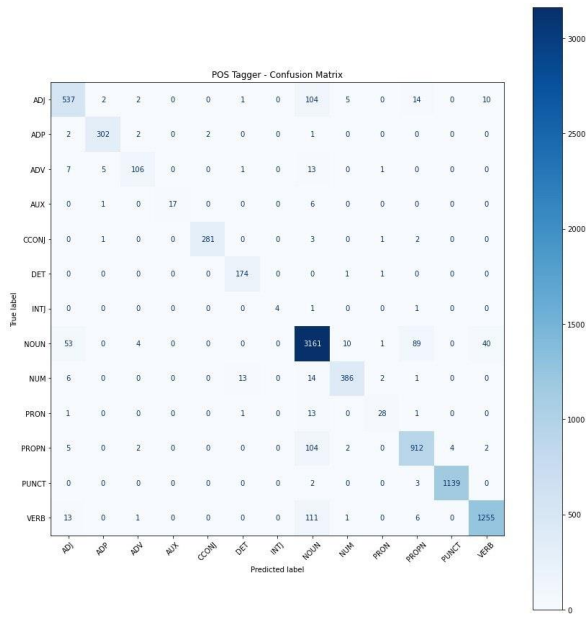
Tablo2: Genel Performans Sonuçları

KARIŞIKLIK MATRİSLERİ



Resim 3: HMM karışıklık matrisi
4: CRF karışıklık matrisi

Resim



Resim 5: Spacy karışıklık matrisi

TARTIŞMA VE SONUÇ

Sonuçlar, spaCy'nin dönüştürücü tabanlı POS etiketleme yaklaşımının, özellikle az veriyle çalışan geleneksel HMM ve CRF modellere kıyasla daha tutarlı ve yüksek doğruluklu çıktılar verdiğini göstermektedir. Geleneksel HMM ve CRF gibi istatistiksel modellere kıyasla spaCy, transformer tabanlı yapısı sayesinde bağlamsal bilgiyi daha etkili şekilde öğrenmiş ve bu da etiketleme doğruluğuna doğrudan yansımıştır.

Bu başarı, modelin önceden büyük veri kümeleri üzerinde eğitilmiş olmasının yanı sıra, **morpheme-level (biçimbirim düzeyinde)** analiz yeteneğinden de kaynaklanmaktadır. Türkçede eklerle kelime türetimi ve çekimi oldukça yaygın olduğundan, bağlamdan doğru biçimbirimsel çözümleme yapabilen modeller daha avantajlı hale gelmektedir.

Ayrıca modelin düşük frekanslı etiketlerde dahi makul F1 skorları elde etmesi, **data sparsity** problemini büyük ölçüde aştığını göstermektedir. Bu, özellikle etiket sayısının fazla olduğu çok sınıflı sınıflandırma problemlerinde önemli bir avantajdır.

Sonuç olarak:

- spaCy modeli, POS etiketleme görevinde yüksek doğruluk ve tutarlılık sağlamıştır.
- Türkçedeki bağlamsal ve biçimbilimsel karmaşıklıklara rağmen başarılı tahminlerde bulunmuştur.
- Transformer tabanlı yaklaşımların, geleneksel yöntemlere göre daha esnek ve güçlü olduğu gözlemlenmiştir.

Daha ayrıntılı sınıf bazlı karşılaştırmalar ve başarı değerleri **Ek-5**'te sunulan tabloda yer almaktadır.

DEMO

Tüm modellerin etiketlemeleri gerçek zamanda test etmek için interactivePoSTester.py geliştirilmiştir. İlgili kod eğitilmiş modelleri yükleyip, kullanıcıdan alacağı cümleleri her modele etikettirip sonuçları raporluyor. Örnek çalışma Resim-6 da bulunmaktadır

```
POS Tagging Demo. Type a sentence and press Enter (or 'quit' to exit).

> Kahramanmaraş'ta "250 Bininci Afet Konutu Anahtar Teslimi ve Kura Çekimi Töreni" Azerbaycan hükümeti ve TOKİ iş birliği ile inşa edilen Azerbaycan Mahallesi'nde 19 Haziran'da düzenlenecek.

spaCy Tagger Output:
Kahramanmaraş'ta/PROPN "/PUNCT 250/NUM Bininci/NOUN Afet/NOUN Konutu/PROPN Anahtar/PROPN Teslimi/NOUN ve/CCONJ Kura/NOUN Çekimi/NOUN Töreni/NOUN "/PUNCT
Azerbaycan/PROPN hükümeti/NOUN ve/CCONJ TOKİ/PROPN iş/NOUN birliği/NOUN ile/CCONJ inşa/NOUN edilen/VERB Azerbaycan/PROPN Mahallesi'nde/NOUN 19/NUM
Haziran'da/PROPN düzenlenecek/VERB ./PUNCT

HMM Tagger Output:
Kahramanmaraş'ta/PROPN "/PUNCT 250/NUM Bininci/NOUN Afet/NOUN Konutu/VERB Anahtar/PUNCT Teslimi/PROPN ve/CCONJ Kura/NOUN Çekimi/NOUN Töreni/VERB "/PUNCT
Azerbaycan/PROPN hükümeti/NOUN ve/CCONJ TOKİ/NOUN iş/NOUN birliği/NOUN ile/CCONJ inşa/NOUN edilen/VERB Azerbaycan/PUNCT Mahallesi'nde/NUM 19/NUM
Haziran'da/NOUN düzenlenecek/VERB ./PUNCT

CRF Tagger Output:
Kahramanmaraş'ta/NOUN "/PUNCT 250/NUM Bininci/ADJ Afet/NOUN Konutu/NOUN Anahtar/PROPN Teslimi/NOUN ve/CCONJ Kura/NOUN Çekimi/NOUN Töreni/NOUN "/PUNCT
Azerbaycan/PROPN hükümeti/NOUN ve/CCONJ TOKİ/PROPN iş/NOUN birliği/NOUN ile/CCONJ inşa/NOUN edilen/VERB Azerbaycan/PROPN Mahallesi'nde/NOUN 19/NUM
Haziran'da/PROPN düzenlenecek/VERB ./PUNCT

> quit
Goodbye!
```

Resim 6: Gerçek zamanlı etiketleme

KAYNAKÇA

- [1] C. A. Bahcevan, E. Kutlu, and T. Yildiz, "Deep Neural Network Architecture for Part-of-Speech Tagging for Turkish Language," in *2018 3rd International Conference on Computer Science and Engineering (UBMK)*, IEEE, Sep. 2018, pp. 235–238. doi: 10.1109/UBMK.2018.8566272.
- [2] B. K. G. Yazar and E. Kilic, "Improving Low-Resource Kazakh-English and Turkish-English Neural Machine Translation Using Transfer Learning and Part of Speech Tags," *IEEE Access*, 2025, doi: 10.1109/ACCESS.2025.3542491.
- [3] E. B. Boltayevich, E. Adali, K. S. Mirdjonovna, A. O. Xolmo'minovna, X. Z. Yuldashevna, and X. Nizomaddin Uktamboy O'G'li, "The Problem of Pos Tagging and Stemming for Agglutinative Languages (Turkish, Uyghur, Uzbek Languages)," in *UBMK 2023 - Proceedings: 8th International Conference on Computer Science and Engineering*, Institute of Electrical and Electronics Engineers Inc., 2023, pp. 57–62. doi: 10.1109/UBMK59864.2023.10286792.

- [4] T. Dincer, B. Karaoglan, and T. Kisl , “A suffix based part-of-speech tagger for Turkish,” in *Proceedings - International Conference on Information Technology: New Generations, ITNG 2008*, 2008, pp. 680–685. doi: 10.1109/ITNG.2008.103.
- [5] E. Ehsani, E. Adali, R. Ehsani, M. Ege Alper, and ref Adali, “Disambiguating Main POS tags for Turkish,” in *24th Conference on Computational Linguistics and Speech Processing, ROCLING 2012*, Chung-Li, Sep. 2012, pp. 202–213. [Online]. Available: <https://www.researchgate.net/publication/235886989>
- [6] A. Murat and S. Ali, “Low-Resource POS Tagging With Deep Affix Representation and Multi-Head Attention,” *IEEE Access*, vol. 12, pp. 66495–66504, 2024, doi: 10.1109/ACCESS.2024.3395454.
- [7] N. Bolucu and B. Can, “Stem-based PoS tagging for agglutinative languages,” in *2017 25th Signal Processing and Communications Applications Conference (SIU)*, IEEE, May 2017, pp. 1–4. doi: 10.1109/SIU.2017.7960386.
- [8] Y. Bektař and S. A.  zel, “The Effect of POS Tag Information on Sentence Boundary Detection in Turkish Texts,” in *2018 Innovations in Intelligent Systems and Applications Conference (ASYU)*, IEEE, Oct. 2018, pp. 1–5. doi: 10.1109/ASYU.2018.8554031.
- [9] K. Oflazer, B. Say, D. Zeynep Hakkani-Tiir, and G. Tiir, “Chapter 15 BUILDING A TURKISH TREEBANK,” 2003.

EKLER

EK 1: ETİKET LİSTESİ

Tag	İngilizce Adı	T�rk�e Terim	�rnek Token
NOUN	Noun	İsim	<i>ev</i>
VERB	Verb	Fiil	<i>git</i>
ADJ	Adjective	Sıfat	<i>g�zel</i>
ADV	Adverb	Zarf	<i>hızlıca</i>
PRON	Pronoun	Zamir	<i>ben</i>
DET	Determiner	Belirleyici	<i>bir</i>
ADP (POSTP)	Postposition	İlge�	<i>i�in</i>
CCONJ (CONJ)	Conjunction	Bağla�	<i>ve</i>
NUM	Numeral	Sayı	<i>iki</i>

INTJ	Interjection	Ünlem	<i>haydi</i>
QUES	Question Particle	Soru Eki	<i>mı</i>
DUP	Reduplicator	Yineleme	<i>güzel güzel</i>
PUNCT	Punctuation	Noktalama	.

EK 2: SINIF BAZLI PERFORMANS SONUÇ(HMM)

Etiket	Kesinlik	Duyarlılık	F1-Skoru	Destek
ADJ	0.894	0.641	0.747	752
ADP	0.982	0.870	0.922	369
ADV	0.985	0.430	0.598	149
AUX	0.000	0.000	0.000	21
CCONJ	0.990	0.947	0.968	322
DET	0.913	0.969	0.940	162
INTJ	0.000	0.000	0.000	12
NOUN	0.784	0.821	0.802	3829
NUM	0.671	0.704	0.687	568
PRON	0.000	0.000	0.000	48
PROPN	0.647	0.547	0.593	1311
PUNCT	0.799	0.984	0.882	1467
VERB	0.732	0.768	0.750	1593

Makro Ort.	0.646	0.591	0.607	10603
Ağırlıklı Ort.	0.775	0.779	0.772	10603

EK 3: SINIF BAZLI PERFORMANS SONUÇ(CRF)

Etiket	Kesinlik	Duyarlılık	F1-Skoru	Destek
ADJ	0.890	0.809	0.847	752
ADP	0.975	0.957	0.966	369
ADV	0.901	0.792	0.843	149
AUX	0.889	0.762	0.821	21
CCONJ	0.994	0.975	0.984	322
DET	0.919	0.975	0.946	162
INTJ	1.000	0.833	0.909	12
NOUN	0.884	0.931	0.907	3829
NUM	0.926	0.882	0.904	568
PRON	0.839	0.542	0.658	48
PROPN	0.868	0.866	0.867	1311
PUNCT	0.997	0.985	0.991	1467
VERB	0.944	0.920	0.932	1593
Makro Ort.	0.925	0.864	0.890	10603
Ağırlıklı Ort.	0.917	0.916	0.916	10603

EK 4: SINIF BAZLI PERFORMANS SONUÇ (SPACY)

Etiket	Kesinlik	Duyarlılık	F1-Skoru	Destek
ADJ	0.863	0.804	0.833	675
ADP	0.962	0.984	0.973	309
ADV	0.954	0.782	0.860	133
AUX	1.000	0.708	0.829	24
CCONJ	0.996	0.972	0.984	288
DET	0.926	0.994	0.959	176
INTJ	1.000	0.667	0.800	6
NOUN	0.903	0.927	0.915	3358
NUM	0.944	0.924	0.934	422
PRON	0.849	0.636	0.727	44
PROPN	0.858	0.906	0.882	1031
PUNCT	0.998	0.997	0.998	1144
VERB	0.948	0.907	0.927	1387

Makro Ort.	0.939	0.862	0.894	8997
Ağırlıklı Ort.	0.922	0.922	0.921	8997

EK 5: SINIF BAZLI F1 KARŞILAŞTIRMA

Etiket	HMM F1	CRF F1	spaCy F1
ADJ	0.747	0.847	0.833
ADP	0.922	0.966	0.973
ADV	0.598	0.843	0.860
AUX	0.000	0.821	0.829
CCONJ	0.968	0.984	0.984
DET	0.940	0.946	0.959
INTJ	0.000	0.909	0.800
NOUN	0.802	0.907	0.915
NUM	0.687	0.904	0.934
PRON	0.000	0.658	0.727
PROPN	0.593	0.867	0.882
PUNCT	0.882	0.991	0.998
VERB	0.750	0.932	0.927

